

MASTER.D

Python para Análise de Dados

CASO PRÁTICO

MODELO DE CLASSIFICAÇÃO COM REGRESSÃO LOGÍSTICA

Previsão da Sobrevivência dos Passageiros do Titanic



Autor: Vanilson Manuel

Curso: Python para Análise de Dados

Ano: 2026

ÍNDICE

1. Introdução
2. Objetivos do Projeto
3. Metodologia
 - 3.1 Importação de Bibliotecas
 - 3.2 Carregamento do Dataset
 - 3.3 Pré-processamento dos Dados
 - 3.4 Divisão dos Dados
 - 3.5 Construção do Modelo
4. Resultados do Modelo
5. Análise e Interpretação dos Resultados
6. Conclusão
7. Referências

1. Introdução

Este trabalho tem como objetivo desenvolver um modelo de regressão logística para prever a sobrevivência dos passageiros do Titanic.

A regressão logística é um método estatístico utilizado para problemas de classificação binária, onde o resultado pode assumir valores como 0 (não sobreviveu) ou 1 (sobreviveu).

2. Objetivos do Projeto

- Aplicar técnicas de análise e preparação de dados
- Construir um modelo de regressão logística
- Avaliar o desempenho do modelo
- Interpretar os resultados obtidos

3. Metodologia

3.1 Importação de Bibliotecas

Foram utilizadas bibliotecas como Pandas, NumPy, Statsmodels e Scikit-learn.

3.2 Carregamento do Dataset

O dataset utilizado foi o **titanic_v2.csv**, contendo informações sobre os passageiros do Titanic.

3.3 Pré-processamento dos Dados

Nesta fase foi realizada:

- Remoção de valores nulos
- Seleção de variáveis relevantes
- Transformação de variáveis categóricas em variáveis numéricas

3.4 Divisão dos Dados

Os dados foram divididos em:

- 70% treino

- 30% teste

3.5 Construção do Modelo

Foi utilizado o modelo de regressão logística (Logit) da biblioteca Statsmodels.

4. Resultados do Modelo

O modelo foi avaliado com base em:

- Matriz de confusão
- Taxa de acerto (accuracy)

A matriz de confusão permitiu analisar acertos e erros do modelo.

A taxa de acerto demonstrou a capacidade do modelo em prever corretamente a sobrevivência dos passageiros.

5. Análise e Interpretação dos Resultados

A variável **sexo (sex)** apresenta forte influência na sobrevivência, sendo que passageiros do sexo masculino têm menor probabilidade de sobreviver.

A variável **classe (pclass)** também é relevante, indicando menor sobrevivência na 3ª classe.

A variável **tarifa (fare)** tem impacto positivo, indicando maior probabilidade de sobrevivência para tarifas mais elevadas.

Os valores de **p-value** indicam quais variáveis são estatisticamente significativas ($p < 0.05$).

6. Conclusão

O modelo de regressão logística permitiu prever a sobrevivência dos passageiros do Titanic com base em variáveis relevantes.

O trabalho demonstrou a importância do pré-processamento de dados e da interpretação dos resultados em projetos de machine learning.

Apesar do bom desempenho, o modelo pode ser melhorado com a inclusão de mais variáveis ou outros algoritmos.

7. Referências

- Documentação Python
- Statsmodels Documentation
- Scikit-learn Documentation
- Dataset Titanic (versão acadêmica)